

Projeto de pesquisa Modelagem Preditiva na Área de Saúde

Categoria: Coordenação/avaliação/pesquisa

Regra: 2.3 - 2 pontos por projeto aprovado

Pontos lançados: 2.00

UNIVERSIDADE FEDERAL DA BAHIA

Instituto de Matemática e Estatística

Departamento de Estatística

PROJETO DE PESQUISA MODELAGEM PREDITIVA NA ÁREA DE SAÚDE

Professor: Ricardo Ferreira da Rocha

Cargo: Professor Adjunto A – nível I

Data de ingresso: 13/09/2017

Vínculo: Estatutário

Regime: Dedicação Exclusiva

Lotação: Instituto de Matemática e Estatística/Departamento de Estatística

Período do projeto: de 13/03/2020 a 12/03/2022

1. INTRODUÇÃO

Nesse projeto de pesquisa será apresentado diversos projetos que possuem a seguinte temática em comum: avanços em modelagem preditiva na área de saúde. Serão desenvolvidos diversos trabalhos com o objetivo de propor ferramentas mais acuradas e adequadas para os casos em questão. Em particular, são propostos três projetos na área de análise de sobrevivência e um projeto na área de aprendizado de máquina. Todos se encontram em fase inicial de desenvolvimento. Tais projetos serão desenvolvidos com o auxílio de diversas parcerias, como apresentado mais adiante nesse texto.

2. PROJETOS

2.1 A família de distribuições Beta-pG para modelos de regressão da taxa de cura.

Neste trabalho, proporemos uma família geral de distribuições para modelar dados da taxa de cura, denominada família Beta-pG de distribuições. Essa abordagem baseia-se na inclusão de um parâmetro p na família de distribuições Beta-G, em para torná-lo um modelo de taxa de cura. Será feita uma abordagem de regressão para essa nova família

para acomodar informação de covariáveis. A princípio, será utilizada inferência por máxima verossimilhança. Atenção especial será dada quando G vem de uma distribuição exponencial, ou seja, quando temos a distribuição Beta-pExp. Usaremos alguns estudos de simulação para mostrar a convergência finita das amostras dos parâmetros na distribuição, bem como para comparar o modelo proposto com a abordagem de mistura padrão. Para finalizar, exemplos serão exibidos em um conjunto de dados reais relacionados ao câncer para mostrar se a nova família pode superar o modelo de mistura padrão.

2.2 Um modelo de regressão adequado para dados com subgrupos curados e não curados com base em distribuições defeituosas.

Proporemos um novo modelo de regressão que pode lidar com um cenário específico de dados de sobrevivência. Esse cenário ocorre quando, dada uma covariável categórica, os níveis dessa covariável levam a curvas em que há proporções curadas e alguns de seus níveis não. Frequentemente, esse tipo de dado surge na análise de sobrevivência. Na literatura, as pesquisas usam um modelo de sobrevivência próprio, que não pode capturar adequadamente a cura em todos os níveis, ou usa um modelo de taxa de cura, que se encaixa inadequadamente em um modelo onde não há elementos imunes. Utilizaremos uma abordagem de regressão usando distribuições defeituosas que podem superar esse problema e, portanto, seja considerado mais adequado para esse tipo de dados. Será usado distribuições defeituosas versáteis da literatura, como a Gompertz e Marshall-Olkin Gompertz. Utilizaremos estimativas de máxima verossimilhança, justificadas por simulações numéricas. Ilustraremos as técnicas propostas em conjuntos de dados reais de ensaios clínicos relacionados a pacientes com leucemia.

2.3 O modelo MOMB - Marshall-Olkin Maxwell-Boltzmann: uma nova distribuição defeituosa de dois parâmetros.

A análise de sobrevivência é uma área da estatística necessária para estudar o tempo até que um evento ocorra. Os métodos usuais assumem que todos os indivíduos em estudo estão sujeitos ao evento de interesse. No entanto, há situações em que essa suposição não é real. Modelos baseados em distribuições defeituosas são adequados para analisar dados com essas características. O objetivo deste trabalho é propor uma nova distribuição defeituosa capaz de modelar a taxa de cura. Para isso, um modelo baseado em uma modificação da distribuição Maxwell - Boltzmann, combinada com uma propriedade da família Marshall-Olkin de distribuições, permite gerar novas distribuições com a propriedade de ser defeituosa. Será feito inferência via máxima verossimilhança e seus pressupostos verificados por simulação. Sua validade e utilidade será posta a prova em comparação com outros modelos paralelos da literatura em diversas situações com dados reais da área de saúde. Esperamos que esses modelos seja uma alternativa útil para modelagem de taxa de curados.

2.4 Combinação de redes neurais convolucionais para classificação de imagens de mamografia.

O câncer é o nome dado a um conjunto de mais de 100 doenças que têm em comum o crescimento desordenado de células que invadem tecidos e órgãos, segundo o INCA - Instituto Nacional de Câncer. Em 2018, aproximadamente 18 milhões de novos casos de câncer foram diagnosticados em todo o mundo. Entre eles, o câncer de mama é o que mais afeta mulheres em todo o mundo. No Brasil, entre 2018 e 2019, a incidência de câncer de mama é de 59.700 casos novos. Uma maneira de diagnosticar o câncer de mama é capturar imagens radiográficas (mamografias) para pacientes de alto risco. A mamografia é capaz de identificar alterações suspeitas no câncer antes do início dos sintomas e sua análise é feita por radiologistas, que verificam a existência de câncer de mama. Uma maneira de ajudar esses profissionais a classificar imagens de mamografia é usar algumas técnicas computacionais. O diagnóstico baseado em técnicas computacionais pode ajudar o médico a tomar uma decisão mais precisa. Uma técnica computacional amplamente usada para analisar imagens é a CNN - Convolutional Neural Networks. Este trabalho tem o objetivo geral de demonstrar os benefícios da implementação de CNNs para previsão de câncer em dados radiográficos. Para isso, será utilizado um banco de dados fornecido pelo hospital de oncologia A.C.Camargo, especializado no diagnóstico, tratamento e pesquisa de câncer. Serão utilizadas técnicas de aprendizado de máquina profundo, transferência de aprendizado e combinação de modelos, para encontrar o melhor algoritmo preditivo para os dados do hospital.

3. CRONOGRAMA

Esse projeto tem um período de dois anos, desde março de 2020 até março de 2022. Os projetos acima descritos serão desenvolvidos nesse intervalo de tempo, conforme a maior conveniência do momento.

4. RESULTADOS ESPERADOS

Este projeto de pesquisa é composto por subprojetos que serão desenvolvidos durante a vigência do mesmo. Em princípio, os objetivos centrais dos subprojetos estão vinculados à formulação de modelos, estudo de suas propriedades, proposição de metodologias de estimação, investigação da eficiência dos procedimentos de estimação, obtenção de testes e intervalos de confiança, verificação de características dos modelos via procedimentos de simulação e a generalização dos modelos mais comumente utilizados na área. As propostas deste projeto visam contribuir positivamente para o desenvolvimento na área de pesquisa estatística, apontar novos resultados em modelos de bastante relevância prática, além de estender e complementar certos resultados já encontrados. As metas desse projeto de pesquisa são: escrever quatro manuscritos publicáveis em periódicos internacionais, cada um baseado em um dos subprojetos listados acima. Na medida do possível, serão escolhidos

periódicos com Qualis Capes B1 ou superior na área de Matemática/Probabilidade e Estatística.

5. PARCEIROS DE PESQUISA

- Saralees Nadarajah, University of Manchester, Manchester, Reino Unido.
- Vera Tomazella, Universidade Federal de São Carlos, São Carlos, Brasil.
- Francisco Louzada, Universidade de São Paulo, São Carlos, Brasil
- Vinicius Calsavara, A.C.Camargo Cancer Center, São Paulo, Brasil.
- Agatha Rodrigues, Universidade de São Paulo, São Paulo, Brasil.
- Juliana Scudilio, Universidade de São Paulo, São Carlos, Brasil.
- Fernando Moraes, Universidade de São Paulo, São Carlos, Brasil.

6. REFERÊNCIAS

- Balka, J., Desmond, A. F., McNicholas, P. D., 2011. Bayesian and likelihood inference for cure rates based on defective inverse gaussian regression models. *Journal of Applied Statistics* 38 (1), 127–144.
- Cox, D. R., 1972. Regression models and life-tables (with discussion). *Journal of the Royal Statistical Society B* (34(2)).
- Ibrahim, J. G., Chen, M.-H., Sinha, D., 2005. Bayesian Survival Analysis. Wiley Online Library. Price, D. L., Manatunga, A. K., 2001. Modelling survival data with a cured fraction using frailty models. *Statistics in medicine* 20 (9-10), 1515–1527.
- Rocha, R., Nadarajah, S., Tomazella, V., Louzada, F., 2015a. Two new defective distributions based on the Marshall–Olkin extension. *Lifetime data analysis*, 1–25.
- Rocha, R., Nadarajah, S., Tomazella, V., Louzada, F., 2017. A new class of defective models based on the Marshall–Olkin family of distributions for cure rate modeling. *Computational Statistics & Data Analysis* 107, 48–63.
- Rocha, R., Nadarajah, S., Tomazella, V., Louzada, F., Eudes, A., 2015b. New defective models based on the Kumaraswamy family of distributions with application to cancer data sets. *Statistical methods in medical research*, 1–15.
- Rocha, R., Tomazella, V., Louzada, F., 2014. Inferência clássica e bayesiana para o modelo de fração de cura Gompertz defeituoso. *Revista Brasileira de Biometria* 32 (1), 104–114.